

ANALISIS EDA, PREPROCESSING, DAN REGRESI LINEAR

**Penerapan Feature Engineering
Berbasis Waktu & One-Hot Encoding Spesifikasi
Kendaraan**

Disusun Oleh: Euis Fahira Yuningsih-2488010055

INFORMASI & PROFIL DATASET

Dataset sekunder harga mobil bekas (Vehicle Dataset) berisi 301 baris data (observasi) dan 9 kolom (fitur).

Struktur Fitur

- Car_Name: Nama/model kendaraan (kategorikal/teks).
- Year: Tahun pembuatan kendaraan (numerik).
- Selling_Price: Harga jual bekas saat ini (Target Variable - Lakhs).
- Present_Price: Harga jual baru unit kendaraan di showroom (Lakhs).
- Kms_Driven: Total jarak yang telah ditempuh dalam KM (numerik).
- Fuel_Type: Tipe bahan bakar (Petrol, Diesel, CNG).
- Seller_Type: Jenis penjual (Dealer, Individual).
- Transmission: Jenis transmisi (Manual, Automatic).
- Owner: Jumlah pemilik sebelumnya (0, 1, 3).

FOKUS LATIHAN & PIPELINE PEMODELAN

01

Exploratory Data Analysis (EDA)

Menganalisis sebaran harga jual, jarak tempuh, serta tipe spesifikasi kendaraan (bahan bakar, transmisi, penjual).

02

Feature Engineering Berbasis Waktu

Mengubah variabel Year (tahun pembuatan) menjadi Vehicle_Age (umur kendaraan saat ini) untuk menghitung depresiasi harga secara linear.

03

Encoding Spesifikasi Kendaraan

Mengonversi data kategorikal (Fuel_Type, Seller_Type, Transmission) menjadi matriks angka biner (0 atau 1) via One-Hot Encoding.


03

Regresi Linear & Evaluasi

Melatih model Linear Regression serta mengukur performanya menggunakan metrik R^2 , MAE, dan RMSE.


EDA – ANALISIS UNIVARIAT KOLOM NUMERIK & KATEGORIKAL

1. GRAFIK SELLING PRICE (KARAKTERISTIK HARGA JUAL KENDARAAN)



- Sebaran data sangat miring ke kanan (right-skewed).
- Konsentrasi puncak utama (mode) berada di rentang 0 – 5 Lakhs (paling banyak di kisaran 1 – 3 Lakhs). Ini menunjukkan mayoritas pasar mobil bekas didominasi oleh mobil murah/ekonomis.
- Frekuensi mobil terus menurun secara drastis untuk harga di atas 10 Lakhs.
- Garis tengah (median) berada di kisaran 3 – 4 Lakhs.
- Kotak hijau (Interquartile Range / IQR) mencakup rentang harga dari sekitar 1.5 hingga 6 Lakhs.
- Terdapat banyak titik outlier di atas nilai 12 Lakhs hingga yang tertinggi mencapai 35 Lakhs. Titik-titik ini mewakili mobil kelas mewah/premium atau mobil yang umurnya masih sangat baru.


2. GRAFIK YEAR (TAHUN PEMBUATAN KENDARAAN)



- Sebaran data miring ke kiri (left-skewed).
- Mayoritas unit mobil bekas yang dijual adalah keluaran tahun 2014 – 2017, dengan puncak tertinggi di tahun 2015 (lebih dari 60 unit).
- Jumlah unit mobil buatan tahun tua (di bawah 2010) sangat sedikit.
- Rentang tahun pembuatan mobil dominan berada di antara 2012 hingga 2016.
- Terdapat beberapa outlier di bawah tahun 2007 (mobil buatan tahun 2003–2006). Hal ini makin memperkuat alasan mengapa fitur Year diubah menjadi Vehicle_Age agar tren umur mobil lebih mudah dipelajari oleh model regresi.


EDA – ANALISIS UNIVARIAT KOLOM NUMERIK & KATEGORIKAL

3. GRAFIK PRESENT_PRICE (HARGA BARU DI SHOWROOM)



- Polanya mirip dengan Selling_Price, yaitu right-skewed.
- Sebagian besar harga baru mobil berada di bawah 10 Lakhs.
- Nilai median harga baru berada di sekitar 5 – 6 Lakhs.
- Terdapat outlier bernilai sangat tinggi mencapai 90 Lakhs. Perbedaan skala yang lebar ini yang menyebabkan timbulnya outlier pada harga jual bekasnya.


4. GRAFIK KMS_DRIVEN (JARAK TEMPUH KENDARAAN)



- Mayoritas mobil memiliki akumulasi pemakaian jarak tempuh di rentang 10.000 – 60.000 KM.
- Nilai median berada di sekitar 35.000 KM.
- Ada titik-titik pemakaian ekstrem (outlier) di atas 100.000 KM, bahkan ada yang mencapai 500.000 KM.


EDA – ANALISIS UNIVARIAT KOLOM NUMERIK & KATEGORIKAL

4. GRAFIK OWNER (RIWAYAT KEPEMILIKAN)



- Data sangat tidak seimbang (highly imbalanced).
- Hampir seluruh data (sekitar 290 unit dari total 301) bernilai 0 (artinya mobil dari pemilik pertama).
- Hanya sedikit sekali mobil dengan status kepemilikan ke-1 (tangan kedua) atau ke-3.
- Karena variasinya sangat minim, fitur Owner memiliki kontribusi yang relatif kecil dalam memprediksi harga dibanding Present_Price atau Vehicle_Age.


5. DISTRIBUSI FREKUENSI: FUEL_TYPE (JENIS BAHAN BAKAR)



- Petrol (Bensin): 239 kendaraan (kategori yang paling dominan).
- Diesel: 60 kendaraan.
- CNG (Compressed Natural Gas): 2 kendaraan (kategori yang paling sedikit).
- Kesimpulan: Mayoritas kendaraan dalam dataset menggunakan bahan bakar bensin (Petrol).


EDA – ANALISIS UNIVARIAT KOLOM NUMERIK & KATEGORIKAL

6. DISTRIBUSI FREKUENSI: SELLER_TYPE (TIPE PENJUAL)



- Dealer (Dealer Resmi/Dealer Mobil Bekas): 195 kendaraan.
- Individual (Penjual Perorangan/Pribadi): 106 kendaraan.
- Kesimpulan: Sebagian besar kendaraan dijual melalui Dealer dibandingkan penjual perorangan.


7. DISTRIBUSI FREKUENSI: TRANSMISSION (TRANSMISI)



- Manual: 261 kendaraan.
- Automatic (Otomatis): 40 kendaraan.
- Kesimpulan: Kendaraan bermesin Manual jauh lebih mendominasi dataset dibandingkan kendaraan otomatis.


EDA – ANALISIS BIVARIAT FITUR NUMERIK & SELLING PRICE

1. HUBUNGAN ANTARA PRESENT_PRICE DAN SELLING PRICE




- Scatter plot menunjukkan pola sebaran titik yang membentuk garis lurus diagonal ke atas yang sangat jelas. Area arsir merah (confidence interval) di sekitar garis regresi berukuran sangat sempit, menandakan tingkat kepastian yang tinggi dalam hubungan linier ini.
- Terdapat korelasi positif yang sangat kuat. Nilai harga baru/harga saat ini (Present_Price) merupakan penentu paling dominan terhadap nilai jual kembali mobil. Semakin tinggi kelas/harga awal kendaraan saat dibeli, semakin tinggi pula estimasi harga bekasnya di pasar.

2. HUBUNGAN ANTARA KMS_DRIVEN DAN SELLING PRICE



- Sebagian besar data terkonsentrasi pada akumulasi jarak tempuh di bawah 100.000 km. Garis regresi merah cenderung datar dengan kemiringan yang sangat kecil, serta pita ketidakpastian (shade) yang melebar di area jarak tempuh tinggi.
- Jarak tempuh kendaraan (Kms_Driven) tidak secara langsung menurunkan harga jual secara drastis dalam dataset ini. Kendaraan dengan jarak tempuh tinggi masih bisa memiliki harga jual yang relatif stabil jika faktor pendukung lainnya (seperti jenis mobil atau kondisi mesin) masih berada dalam kondisi ideal.


3. HUBUNGAN ANTARA YEAR DAN SELLING PRICE



- Tren regresi menunjukkan arah positif dari tahun ke tahun. Terlihat peningkatan variasi dan sebaran nilai Selling_Price pada mobil-mobil keluaran tahun terbaru (sekitar tahun 2014 hingga 2018).
- Faktor usia kendaraan memegang peranan penting. Mobil dengan tahun pembuatan yang lebih muda/baru mengalami depresiasi nilai yang lebih sedikit, sehingga mampu mempertahankan harga pasar yang jauh lebih tinggi dibandingkan mobil yang sudah berusia tua.


EDA – ANALISIS BIVARIAT FITUR KATEGORIKAL & SELLING PRICE

1. PENGARUH FUEL_TYPE TERHADAP SELLING PRICE




- Boxplot untuk Diesel memiliki garis tengah (median) serta rentang interkuartil (IQR) yang jauh lebih tinggi dibanding Petrol maupun CNG. Kategori Petrol memiliki banyak nilai ekstrim/outlier di bagian atas.
- Kendaraan berbahan bakar Diesel secara signifikan memiliki nilai pasar yang lebih tinggi. Hal ini sejalan dengan kondisi pasar di mana mobil diesel umumnya memiliki kapasitas mesin yang lebih besar, daya tahan yang tinggi, serta harga beli awal yang juga lebih mahal dibandingkan mobil bensin.

2. PENGARUH SELLER_TYPE TERHADAP SELLING PRICE



- Kotak distribusi untuk kelompok Dealer berada jauh di atas kelompok Individual. Penjualan oleh Individual terkonsentrasi rapat di rentang harga yang sangat rendah (mendekati nol).
- Kendaraan yang ditawarkan oleh Dealer mencakup mobil-mobil dengan nilai jual premium dan menengah. Sebaliknya, transaksi antar penjual perorangan (Individual) didominasi oleh unit kendaraan berharga murah (seperti kendaraan roda dua atau mobil tua).


3. PENGARUH TRANSMISSION TERHADAP SELLING PRICE



- Transmisi Automatic menunjukkan rentang sebaran harga yang sangat luas hingga mencapai rentang harga tinggi. Sementara itu, transmisi Manual terkumpul pada kisaran harga di bawah 10 Lakhs.
- Mobil dengan transmisi otomatis (Automatic) memiliki nilai jual kembali yang jauh lebih tinggi. Tingginya minat pasar terhadap kenyamanan transmisi otomatis pada segmen mobil menengah ke atas menjadi pendorong utama perbedaan harga ini.

MATRIKS KORELASI & HEATMAP

=== ANALISIS MULTIVARIAT: MATRIKS KORELASI & HEATMAP ===



- Present_Price vs Selling_Price ($r = 0.88$): Kategori korelasi positif sangat kuat. Angka 0.88 mempertegas secara matematis bahwa Present_Price adalah variabel penentu utama (fitur terpenting) untuk memprediksi harga jual Selling_Price.
- Year vs Kms_Driven ($r = -0.52$): Korelasi negatif sedang. Hal ini sangat logis secara realitas: semakin tua tahun pembuatan mobil, semakin besar akumulasi jarak tempuh yang telah dilalui kendaraan tersebut.
- Year vs Selling_Price ($r = 0.24$): Korelasi positif moderat. Mengindikasikan bahwa tahun pembuatan secara konsisten memberikan kontribusi terhadap kenaikan harga jual.
- Variabel Korelasi Rendah (Owner & Kms_Driven vs Selling_Price): Korelasi Owner terhadap Selling_Price sebesar -0.09. Korelasi Kms_Driven terhadap Selling_Price sebesar 0.03.

PREPROCESSING DATA-PEMBERSIHAN DATA & PEMBUATAN FITUR BARU

HANDLING DUPLICATES (PEMBERSIHAN DATA)

- Langkah: Menghapus baris data terduplikasi (df.drop_duplicates()).
- Tujuan: Mencegah data leakage dan bias model dari data ganda.
- Hasil: Dataset bersih terdiri dari 299 baris data.

```
# Menghapus baris duplikat
df_clean = df.drop_duplicates().copy()
print(f"Jumlah baris setelah duplikat dihapus: {df_clean.shape[0]}")

... Jumlah baris setelah duplikat dihapus: 299
```

FEATURE ENGINEERING (MEMBUAT FITUR VEHICLE_AGE)

- Langkah: Menghitung selisih tahun saat ini dengan tahun pembuatan (datetime.now().year - Year).
- Tujuan: Mengubah data tahun menjadi variabel numerik kuantitatif (usia kendaraan).
- Manfaat: Usia kendaraan lebih intuitif untuk mengukur depresiasi harga pada model machine learning.

```
***
      Year  Vehicle_Age
0  2014         12
1  2013         13
2  2017          9
3  2011         15
4  2014         12
```

PREPROCESSING DATA-SELEKSI FITUR & TRANSFORMASI DATA

FEATURE SELECTION (PENGHAPUSAN KOLOM)

- Kolom yang Dihapus: Car_Name (terlalu banyak nilai unik/high cardinality) dan Year (sudah diwakili oleh Vehicle_Age).
- Hasil: Tersisa 8 kolom utama (Selling_Price, Present_Price, Kms_Driven, Fuel_Type, Seller_Type, Transmission, Owner, Vehicle_Age).

KATEGORICAL ENCODING (ONE-HOT ENCODING)

- Langkah: Mengubah kolom teks (Fuel_Type, Seller_Type, Transmission) menjadi variabel biner (0 dan 1).
- Tujuan: Memungkinkan algoritma machine learning memproses data kategorikal tanpa membuat asumsi urutan/hirarki (ordinality).
- hasil:

```
--- Data Hasil Encoding ---
```

	Selling_Price	Present_Price	Kms_Driven	Owner	Vehicle_Age	Fuel_Type_Diesel	Fuel_Type_Petrol	Seller_Type_Individual	Transmission_Manual
0	3.35	5.59	27000	0	12	False	True	False	True
1	4.75	9.54	43000	0	13	True	False	False	True
2	7.25	9.85	6900	0	9	False	True	False	True
3	2.85	4.15	5200	0	15	False	True	False	True
4	4.60	6.87	42450	0	12	True	False	False	True

PREPROCESSING DATA-PEMBAGIAN DATA LATIH & DATA UJI

PEMISAHAN FEATURE (X) DAN TARGET (Y)

- Feature (X): 8 variabel independen untuk memprediksi harga => Dimensi: (299, 8)
- Target (y): Variabel Selling_Price yang ingin diprediksi => Dimensi: (299,)

```
# Variabel Independen (X) dan Variabel Dependen (y)
X = df_encoded.drop(columns=['Selling_Price'])
y = df_encoded['Selling_Price']

print("Dimensi X (Fitur):", X.shape)
print("Dimensi y (Target):", y.shape)
```

```
Dimensi X (Fitur): (299, 8)
Dimensi y (Target): (299,)
```

TRAIN-TEST SPLIT (RASIO 80:20)

- Data Latih (X_train): 239 sampel (80%) => Digunakan untuk melatih dan mengoptimalkan model.
- Data Uji (X_test): 60 sampel (20%) => Digunakan untuk menguji dan mengevaluasi performa akhir model.

```
from sklearn.model_selection import train_test_split

# Membagi dataset menjadi training set dan testing set
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Jumlah Data Latih (X_train): {X_train.shape[0]}")
print(f"Jumlah Data Uji (X_test): {X_test.shape[0]}")
```

```
Jumlah Data Latih (X_train): 239
Jumlah Data Uji (X_test): 60
```

REGRESI LINEAR – PEMODELAN & EVALUASI REGRESI LINEAR

1. PELATIHAN MODEL (TRAINING)

```
from sklearn.linear_model import LinearRegression

# Inisialisasi model regresi linear
model = LinearRegression()

# Melatih model menggunakan data latih
model.fit(X_train, y_train)

print("Model Regresi Linear Berhasil Dilatih!")
```

Model Regresi Linear Berhasil Dilatih!

- Menggunakan algoritma Linear Regression dari pustaka scikit-learn.
- Model dilatih menggunakan 80% data latih (X_train, y_train) untuk mempelajari pola hubungan antar fitur.

2. PENGUJIAN & PREDIKSI (PREDICTION)

```
# Memprediksi harga jual untuk data uji
y_pred = model.predict(X_test)

# Menampilkan 5 sampel perbandingan nilai aktual vs prediksi
hasil_prediksi = pd.DataFrame({'Aktual': y_test.values, 'Prediksi': y_pred})
display(hasil_prediksi.head())
```

	Aktual	Prediksi
0	8.99	7.501922
1	8.35	7.791521
2	0.45	1.366444
3	7.45	7.009419
4	5.25	11.163290

Model melakukan prediksi harga jual pada 20% data uji (X_test) yang belum pernah dilihat sebelumnya untuk menguji akurasi generalisasi.

3. METRIK EVALUASI PERFORMA MODEL

```
=== EVALUASI PERFORMA MODEL ===
MAE (Mean Absolute Error) : 1.4729
RMSE (Root Mean Sq. Error) : 2.5240
R2 Score (Koef. Determinasi): 0.7528
```

- MAE (Mean Absolute Error) = 1.4729: Rata-rata kesalahan prediksi harga jual menyimpang sekitar 1.47 Lakhs dari harga asli.
- RMSE (Root Mean Squared Error) = 2.5240: Mengukur besarnya tingkat kesalahan prediksi dengan memberi bobot lebih pada error yang besar.
- R² Score (Koefisien Determinasi) = 0.7528 (75.28%): Model mampu menjelaskan 75.28% variasi harga jual, sedangkan sisa 24.72% dipengaruhi oleh faktor lain di luar model.

REGRESI LINEAR – ANALISIS KOEFISIEN FITUR & VISUALISASI PREDIKSI

1. INTERCEPT & TABEL KOEFISIEN FITUR (BOBOT MODEL)

Intercept (Konstanta): 6.6298		
--- Koefisien Fitur ---		
	Fitur	Koefisien
4	Fuel_Type_Diesel	2.139111
5	Fuel_Type_Petrol	0.690622
2	Owner	0.642856
0	Present_Price	0.437187
1	Kms_Driven	-0.000011
3	Vehicle_Age	-0.331041
6	Seller_Type_Individual	-1.301377
7	Transmission_Manual	-1.572125

- Intercept (Konstanta = 6.6298): Nilai dasar (baseline) estimasi harga jual adalah 6.6298 Lakhs, yaitu estimasi teoritis ketika seluruh nilai fitur pendukung bernilai 0.
- Koefisien Positif (Pendorong Harga): Fitur dengan nilai positif terbesar (seperti Present_Price) memberikan dampak peningkatan harga jual secara langsung.
- Koefisien Negatif (Penurun Harga): Fitur seperti Vehicle_Age bernilai negatif, mengindikasikan bahwa setiap bertambahnya usia kendaraan akan menurunkan (depresiasi) harga jual.
- Kesimpulan Tabel: Urutan fitur (sort_values) memperlihatkan variabel mana yang paling dominan memengaruhi naik/turunnya nilai jual mobil di pasar.

2. VISUALISASI SCATTER PLOT: NILAI AKTUAL VS PREDIKSI



- Akurasi Tinggi pada Rentang Harga Umum: Sebagian besar titik hijau berkumpul rapat di sepanjang garis merah pada kisaran harga 0–10 Lakhs, membuktikan bahwa model sangat presisi dan stabil dalam memprediksi harga mobil di pasar normal.
- Kelemahan pada Nilai Ekstrem: Model cenderung memprediksi lebih rendah (under-prediction) pada mobil berharga sangat tinggi di atas 30 Lakhs, serta menghasilkan nilai negatif pada harga aktual mendekati 0 akibat sifat alami garis lurus regresi linear.

KESIMPULAN

Berdasarkan alur analisis data secara keseluruhan, hasil Exploratory Data Analysis (EDA) menunjukkan bahwa mayoritas kendaraan berbahan bakar bensin (Petrol), bertransmisi manual, dan dijual oleh Dealer, di mana variabel harga baru (Present_Price), transmisi otomatis, dan tipe mesin diesel menjadi pendorong utama tingginya harga jual (Selling_Price). Setelah melalui tahap preprocessing—termasuk penghapusan duplikat hingga tersisa 299 data, pembuatan fitur Vehicle_Age, seleksi 8 fitur utama, serta pembagian data 80:20—model Regresi Linear berhasil dilatih dan menghasilkan R^2 Score sebesar 75.28% dengan rata-rata kesalahan (MAE) 1.4729 Lakhs, yang terbukti sangat presisi dan stabil untuk memprediksi harga kendaraan pada kisaran pasar normal (0–10 Lakhs) meskipun mengalami sedikit under-prediction pada kendaraan berharga ekstrem di atas 30 Lakhs.



**THANK
YOU**