

INDRI SETIAWATI 2488010077

EXPLORASI DATA (CARS.CSV) ANALISIS EDA, PREPROCESSING, DAN REGRESI LINEAR

Analisis mendalam distribusi harga, jarak tempuh, dan karakteristik kendaraan.

Dimensi & Ringkasan Data

Struktur keseluruhan dan tipe data dari setiap kolom.

301

Total Baris Data

9

TotalKolom Fitur

0

Nilai Hilang (Missing Value)

--- 5 Baris Pertama Data ---					
	Car_Name	Year	Selling_Price	Present_Price	Kms_Driv
0	ritz	2014	3.35	5.59	270
1	sx4	2013	4.75	9.54	430
2	ciaz	2017	7.25	9.85	69
3	wagon r	2011	2.85	4.15	52
4	swift	2014	4.60	6.87	424

Fuel_Type	Seller_Type	Transmission	Owner
Petrol	Dealer	Manual	0
Diesel	Dealer	Manual	0
Petrol	Dealer	Manual	0
Petrol	Dealer	Manual	0
Diesel	Dealer	Manual	0

01

Exploratory Data Analysis

Menganalisis sebaran harga jual, jarak tempuh, dan spesifikasi kendaraan.

02

Feature Engineering

Mengubah variabel Year menjadi Vehicle_Age untuk mengukur depresiasi harga.

03

One-Hot Encoding spesifikasi dan pelatihan model Regresi Linear serta evaluasi metrik.

Komposisi Tipe Data

Klasifikasi variabel numerik dan kategorikal dalam dataset.

#Numerik (5 Kolom)

Year: Tahun pembuatan mobil

Selling_Price: Harga jual saat ini

Present_Price: Harga pasaran baru

Kms_Driven: Total jarak tempuh

Owner: Jumlah pemilik sebelumnya

AKategorikal (4 Kolom)

Car_Name: Nama atau model mobil





Fuel_Type: Jenis bahan bakar

Seller_Type: Jenis penjual (Dealer/Individu)

Transmission: Jenis transmisi (Manual/Auto)





Analisis Univariat: Variabel Numerik

Visualisasi distribusi menggunakan Histogram, KDE, dan Boxplot untuk deteksi outlier.




Analisis Univariat: Variabel Numerik

Visualisasi distribusi menggunakan Histogram, KDE, dan Boxplot untuk deteksi outlier.



Analisis Univariat: Variabel Numerik

Visualisasi distribusi menggunakan Histogram, KDE, dan Boxplot untuk deteksi outlier.



Temuan Utama Fitur Numerik

Pola distribusi harga jual dan jarak tempuh kendaraan.

Distribusi Harga Jual

Condong ke kanan (right-skewed) dengan sebagian besar mobil berharga rendah.

Outlier Jarak Tempuh




Terdeteksi nilai pencilan pada Kms_Driven yang menunjukkan jarak sangat tinggi.

Kepemilikan Mobil


Mayoritas kendaraan berada pada tingkat kepemilikan pertama (Owner = 0).

Analisis Univariat: Variabel Kategorikal


Distribusi frekuensi kategori bahan bakar, tipe penjual, dan jenis transmisi.



Hubungan antara Present_Price dan Selling Price




Hubungan antara Kms_Driven dan Selling Price






ANALISIS BIVARIAT: FITUR NUMERIK VS SELLING PRICE

Hubungan antara Year dan Selling Price




Grafik tersebut menunjukkan bahwa harga baru (Present_Price) menjadi penentu utama harga jual karena berkorelasi sangat kuat, jarak tempuh (Kms_Driven) tidak menurunkan harga secara drastis, dan tahun pembuatan (Year) membuktikan bahwa mobil yang lebih muda memiliki depresiasi lebih kecil sehingga harganya lebih tinggi.

ANALISIS BIVARIAT: FITUR KATEGORIKAL VS SELLING PRICE



=== ANALISIS MULTIVARIAT: MATRIKS KORELASI & HEATMAP ===



Matriks korelasi Pearson ini menunjukkan hubungan antar fitur numerik, di mana Present_Price memiliki korelasi positif terkuat (0.88) terhadap Selling_Price, sementara Year dan Kms_Driven menunjukkan korelasi negatif sedang (-0.52) karena mobil yang lebih tua cenderung memiliki jarak tempuh yang lebih tinggi.

Jumlah missing value per kolom

```
--- Jumlah Missing Values per Kolom ---
Car_Name      0
Year          0
Selling_Price 0
Present_Price 0
Kms_Driven    0
Fuel_Type     0
Seller_Type   0
Transmission  0
Owner         0
dtype: int64

Jumlah Baris Duplikat: 2
```

Statistik Deskriptif untuk numerik dan kategori

```
--- Statistik Deskriptif untuk Kolom Numerik ---
```


	Year	Selling_Price	Present_Price	Kms_Driven	Owner
count	301.000000	301.000000	301.000000	301.000000	301.000000
mean	2013.627907	4.661296	7.628472	36947.205980	0.043189
std	2.891554	5.082812	8.644115	38886.883882	0.247915
min	2003.000000	0.100000	0.320000	500.000000	0.000000
25%	2012.000000	0.900000	1.200000	15000.000000	0.000000
50%	2014.000000	3.600000	6.400000	32000.000000	0.000000
75%	2016.000000	6.000000	9.900000	48767.000000	0.000000
max	2018.000000	35.000000	92.600000	500000.000000	3.000000

```
--- Statistik Deskriptif untuk Kolom Kategori (Objek) ---
```


	Car_Name	Fuel_Type	Seller_Type	Transmission
count	301	301	301	301
unique	98	3	2	2
top	city	Petrol	Dealer	Manual
freq	26	239	195	261

Visualisasi Distribusi Target & Korelasi

Distribusi Harga Jual (Selling Price)



Matriks Korelasi Fitur Numerik



Preprocessing

Handling Duplicates (Pembersihan Data)

```
# Menghapus baris duplikat
df_clean = df.drop_duplicates().copy()
print(f"Jumlah baris setelah duplikat dihapus: {df_clean.shape[0]}")

... Jumlah baris setelah duplikat dihapus: 299
```

Feature Engineering (Membuat Fitur Umur Kendaraan)

```
from datetime import datetime

# Mengambil tahun saat ini
tahun_sekarang = datetime.now().year

# Menghitung umur kendaraan
df_clean['Vehicle_Age'] = tahun_sekarang - df_clean['Year']

# Menampilkan hasil fitur baru
display(df_clean[['Year', 'Vehicle_Age']].head())
```

	Year	Vehicle_Age
0	2014	12
1	2013	13
2	2017	9
3	2011	15
4	2014	12

Pemisahan Feature (X) dan Target (y)

```
# Variabel Independen (X) dan Variabel Dependen (y)
X = df_encoded.drop(columns=['Selling_Price'])
y = df_encoded['Selling_Price']

print("Dimensi X (Fitur):", X.shape)
print("Dimensi y (Target):", y.shape)
```

Dimensi X (Fitur): (299, 8)
Dimensi y (Target): (299,)

Feature Selection (Penghapusan Kolom Tidak Relevan)

```
# Menghapus kolom Car_Name dan Year
df_prep = df_clean.drop(columns=['Car_Name', 'Year'])

print("Kolom tersisa setelah drop:")
print(df_prep.columns.tolist())

Kolom tersisa setelah drop:
['Selling_Price', 'Present_Price', 'Kms_Driven', 'Fuel_Type', 'Seller_Type', 'Transmission', 'Owner', 'Vehicle_Age']
```

Preprocessing

.. --- Data Hasil Encoding ---

	Selling_Price	Present_Price	Kms_Driven	Owner	Vehicle_Age	Fuel_Type_Diesel	Fuel_Type_Petrol	Seller_Type_Individual	Transmission_Manual
0	3.35	5.59	27000	0	12	False	True	False	True
1	4.75	9.54	43000	0	13	True	False	False	True
2	7.25	9.85	6900	0	9	False	True	False	True
3	2.85	4.15	5200	0	15	False	True	False	True
4	4.60	6.87	42450	0	12	True	False	False	True

Membagi data menjadi Data Latih (80%) dan Data Uji (20%).

```
from sklearn.model_selection import train_test_split

# Membagi dataset menjadi training set dan testing set
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

print(f"Jumlah Data Latih (X_train): {X_train.shape[0]}")
print(f"Jumlah Data Uji (X_test): {X_test.shape[0]}")
```

Jumlah Data Latih (X_train): 239
Jumlah Data Uji (X_test): 60

REGRESI

Melakukan Prediksi Data Uji

```
# Memprediksi harga jual untuk data uji
y_pred = model.predict(X_test)

# Menampilkan 5 sampel perbandingan nilai aktual vs prediksi
hasil_prediksi = pd.DataFrame({'Aktual': y_test.values, 'Prediksi': y_pred})
display(hasil_prediksi.head())
```

...	Aktual	Prediksi
0	8.99	7.501922
1	8.35	7.791521
2	0.45	1.366444
3	7.45	7.009419
4	5.25	11.163290


=== EVALUASI PERFORMA MODEL === MAE (Mean Absolute Error) : 1.4729 RMSE (Root Mean Sq. Error) : 2.5240 R² Score (Koef. Determinasi): 0.7528

Intercept (Konstanta): 6.6298

--- Koefisien Fitur ---

	Fitur	Koefisien
4	Fuel_Type_Diesel	2.139111
5	Fuel_Type_Petrol	0.690622
2	Owner	0.642856
0	Present_Price	0.437187
1	Kms_Driven	-0.000011
3	Vehicle_Age	-0.331041
6	Seller_Type_Individual	-1.301377
7	Transmission_Manual	-1.572125

REGRESI
Visualisasi Hasil Regresi



Kesimpulan

- ✓ Data bersih tanpa nilai kosong (missing values), siap digunakan untuk tahap pemodelan.
- ✓ Fitur harga jual dan jarak tempuh menunjukkan variasi signifikan yang memerlukan penanganan outlier.
- ✓ Karakteristik pasar didominasi oleh mobil bensin bertransmisi manual yang dijual melalui dealer.

Secara garis besar, analisis ini berhasil memetakan karakteristik pasar mobil bekas yang didominasi oleh unit bensin bertransmisi manual keluaran dealer resmi. Dari segi pemodelan, penerapan preprocessing—seperti pembersihan data duplikat, rekayasa fitur umur kendaraan (Vehicle_Age), dan one-hot encoding—berperan krusial dalam menghasilkan performa Regresi Linear yang andal dengan tingkat akurasi mencapai 75,28%. Model ini terbukti sangat stabil dalam memprediksi harga mobil di kisaran normal (0–10 Lakhs), meskipun akurasinya sedikit menurun (under-prediction) saat dihadapkan pada unit mobil mewah berharga ekstrem di atas 30 Lakhs.

Terima Kasih
